小组项目选题说明

基于班级讲义的可溯源 AI 出题与生成质量评测模块

小组成员：徐焜、徐高鹏

项目周期：7 周 | 实施方式：基于既有智能教学平台扩展

一、项目背景与目标

教师依据课程讲义编制练习时，需要兼顾考查范围、题型、难度与答案准确性。AI 能够辅助生成题目，但生成内容可能缺乏明确依据，或存在答案错误、表述歧义和重复出题等问题，仅展示生成结果难以证明其教学可用性。

本项目拟在既有智能教学平台上，建设“讲义选材、题目生成、质量自检、教师审核、题卷发布、评测回归”的完整链路。每道题绑定本班讲义的具体切片与定位信息，支持点击核对原文；通过规则校验、模型辅助判定和人工标注评测，形成可追踪、可验证的生成质量证据。

二、项目范围与预期成果

范围	交付内容
核心交付	按讲义及可用定位范围选材；单选、判断、填空三类题目生成；出处定位；有限次重试；教师逐题审核与编辑；题卷发布与基础导出；质量评测与回归门禁。
扩展目标	在核心能力完成后，扩展多选、简答、章节识别、知识点补题与聚类，以及不同切片策略的对比实验。扩展项不作为核心验收前提。
边界说明	AI 结果始终先进入草稿流程。发布后的题卷供后续作业模块接入，本期不包含学生作答、自动批改与成绩管理。现有问答能力纳入评测，不扩展其产品功能。

预期成果包括：可运行的组卷与审核模块、题目溯源展示、质量自检记录、人工标注评测集、基线及对比报告、回归检查脚本、OpenSpec 规约与验证文档。全部能力沿用现有 Docker Compose 本机部署方式。

三、主要功能

3.1 教师设定范围与 AI 组卷

教师选择本班一份或多份讲义，设置整份讲义或指定页码、幻灯片等可用定位范围，并配置题型配比、题量、难度分布及是否生成解析。系统只从本班当前已发布代次的切片中选取素材。素材不足时明确提示，不为凑足题量生成无依据题目。

模型逐题输出结构化结果。每题包含题干、题型、难度、知识点、标准答案、可选解析，以及来源讲义、切片标识、切片序号、定位和字符区间。PDF 对应页码，PPT 对应幻灯片，Word 对应段落，TXT 对应行号；具体粒度以平台实际解析结果为准。

3.2 生成质量自检与有限重试

层次	检查内容
确定性校验	JSON 结构、必填字段、长度与选项数量；答案编号合法；单选仅一个答案、多选答案数量符合约束；填空答案与原文匹配；引用区间合法且引用文本与来源一致。
语义判定	通过课程网关辅助判断答案是否获得来源支持、题目是否有歧义、选项是否互斥、是否包含“以上都对”等低质量设计，以及难度是否合理。模型判定保留原因，供教师复核。
重复检测	先进行文本规范化与精确去重，再利用来源切片相似度筛选候选，结合题干、答案与考查点判定同义重复。切片相似度不直接作为题目重复的结论。
失败处理	按原因分类并有限次重生成；达到重试上限后丢弃候选，保留必要的失败记录。未通过校验的结果不得进入可审核题目集，任务展示实际交付题数与不足原因。

规则校验只证明结构与来源的一致性，不能普遍证明语义正确；模型判定也不替代教师的最终审核。

3.3 教师工作台与题卷发布

工作台展示组卷任务列表、处理进度与失败原因。逐题卡片展示题干、答案、解析、自检结果和可点击来源，支持通过、退回重生成、手工编辑及调整难度与知识点，并支持整卷重生成和基础导出。

修改题干、答案或来源后，相关自检和审核结果失效，需重新校验与确认。发布前由服务端检查题目审核状态及来源有效性；存在未通过审核或来源失效的题目时禁止发布。

四、技术方案与关键设计

4.1 总体架构与技术选型

浏览器通过 web（nginx）访问本站 /api，由 Go API 完成鉴权、组卷管理、审核与查询。worker 消费持久化长任务，完成选材、生成和自检；API 与 worker 访问 MySQL、Qdrant 及私有讲义存储，并仅在服务端调用课程网关。

层次	选型与职责
前端	React + TypeScript，复用既有工程，新增组卷工作台与评测报告页；界面使用中文，以白色为主、红色为辅。
后端与契约	Go，复用现有 HTTP 层、鉴权及 OpenAPI 3.1 契约校验。新增接口同步契约与后端文档副本。
数据与向量	MySQL 8.4 保存题目、来源、题卷、任务和评测数据；Qdrant 复用切片向量及标识类 payload，用于相似素材候选召回。
异步与 AI	复用现有持久化任务机制；后续课程引入消息队列时接入消费者，不另建队列基础设施。出题与语义判定统一经课程网关调用。
部署与规约	沿用 Docker Compose、非 root 和只读根文件系统约束。按独立能力维护 OpenSpec proposal、specs、design、tasks，再实施、验证与归档。

4.2 数据模型

拟新增的核心实体包括：question_items（题目及状态）、question_sources（题目与来源切片、代次、定位和字符区间）、generation_runs（组卷配置及执行统计）、question_papers / question_paper_items（题卷与题目编排）、eval_runs / eval_cases（评测记录与样本）。审核与生成尝试记录的表结构在设计阶段确定，通过版本化迁移落地。

4.3 权限、溯源与任务一致性

MySQL 是切片正文、权限及发布代次的权威来源。向量召回后必须回表校验班级权限与有效代次，教师审核、发布和原文访问也均由服务端鉴权；讲义文件不通过公共静态路径提供。

题目强绑定来源代次。讲义重建或删除后，相关题目标记为“来源失效”并阻止发布或后续使用。任务按有限重试和幂等写入设计，避免重复执行产生重复题目。模型名称、网关地址和密钥不下发浏览器。

五、质量评测与回归方法

5.1 评测集与实验组织

问答评测集拟从原有 20 题扩展至 40-50 题，补充相关切片、可回答性与参考答案标注。出题评测固定讲义版本、组卷要求和评分标准，分层抽取 100-150 道生成题目，覆盖核心题型与难度，由两名组员独立标注答案正确性、出处正确性与表述歧义，分歧经复核确定。

开发调优样本与保留验收样本分开管理。对比实验使用同一批讲义和相同组卷任务，每个配置的新输出均按统一标准评审；记录模型、提示词、切片代次、参数和时间，必要时重复运行以观察波动。人工标注规模为计划目标，不代表已有评测结果。

5.2 指标定义

指标	计算口径
组卷完成率 / 可用率	完成率 = 最终审核通过题数 / 请求题数；候选可用率 = 通过质量审核的候选数 / 已生成候选数。重试产生的候选计入分母，避免只统计最终保留结果。
出处 / 答案正确率	在人工评审样本中，出处位置与支撑内容均正确的比例，以及标准答案正确的比例；同时报告样本量。
重复率 / 覆盖率	重复率 = 样本中除首题外的重复题数 / 样本题数；覆盖率 = 有效题目覆盖的预设知识点数 / 目标知识点总数。
生成耗时	记录端到端任务耗时、每道有效题的平均耗时及重试次数，区分排队时间与处理时间。
问答检索质量	recall@4 = 前 4 个检索结果命中的相关切片数 / 标注相关切片总数，按题平均；MRR 为首个相关结果排名倒数的均值。
拒答 / 忠实度	拒答准确率 = 正确回答或正确拒答的判定数 / 样本数，并分别报告误拒答与漏拒答；忠实度依据回答中的可核验断言是否得到引用内容支持评定。

5.3 对比实验与回归门禁

核心实验比较不同提示词版本及自检开关，输出 JSON 报告与指标对比表。自检关闭仅用于隔离的评测流程，保留结构、权限及来源安全校验，实验输出不得绕过教师审核进入发布流程。切片策略实验作为扩展项，使用独立索引版本保证结果可比。

第 1-2 周先建立并冻结基线、样本与阈值，后续按统一口径比较。确定性检查纳入自动测试，模型与人工指标按固定评测流程形成验收报告；低于预设阈值则回归失败。涉及生成质量的改动通过相应评测后再合并，不以模型自评分数代替人工正确率。

六、小组分工与进度安排

采用两人垂直分工：徐焜负责组卷生成与教师工作台，徐高鹏负责自检、去重与评测。第 1-2 周共同确定接口契约、迁移方案、前端模块边界、自检输入输出和失败原因分类，并共同完成标注规范及基线确认。

周期	徐焜：生成与交互	徐高鹏：质量与评测
W1-2	接口契约、数据迁移、前端骨架；固定核心范围与任务状态。	问答评测集扩充、出题标注方案、评测脚本骨架；共同记录基线。
W3-4	范围选材、结构化生成、持久化任务接入。	确定性自检、语义判定、失败原因分类与接口联调。
W5	溯源落库与定位、有限重试、幂等及来源失效处理。	重复检测、组卷指标计算、人工样本标注与复核。
W6	教师审核、编辑、重生成、题卷发布与基础导出。	对比实验、评测报告、回归门禁与集成验证。
W7	端到端演示、缺陷修复、部署及使用说明。	指标报告成文、验证证据整理；共同完成规约归档。

七、验收标准与风险控制

功能验收：教师可完成“选择本班讲义、提交组卷、查看进度、核对来源、审核编辑、发布题卷”的完整流程；生成失败可追踪，材料不足可说明，来源失效可阻止发布，跨班级访问被服务端拒绝。

工程验收：完成 OpenSpec 严格校验、OpenAPI 契约同步、Go test/vet、前端构建及相关集成测试；在 Docker Compose 环境实测核心流程并记录证据，执行必要的浏览器回归。

质量验收：提交固定评测集、标注规范、基线数字、至少一组提示词对比及自检开关实验、回归判定报告。指标阈值在基线阶段确定并冻结，最终报告同时说明失败案例与适用边界。

风险控制：优先完成三类核心题型与现有定位能力；网关超时和不合格输出采用有限重试；课程消息队列进度不阻塞现有任务机制接入；模型波动通过固定配置、保留样本和复测记录解释。

八、项目特色

本项目将可核对的讲义出处、来源代次失效控制和教师确认引入同一出题流程，并以确定性校验、模型辅助判定和人工评测分层保障质量。交付不仅包含可运行功能，也包含能够说明效果、暴露问题并防止质量退化的评测证据。